

L'impatto della tecnologia nel mondo della musica

Analisi delle collaborazioni, dei temi latenti e della popolarità

Francesco La Rosa · 178327

26 agosto 2026

L'evoluzione tecnologica e l'Ai stanno trasformando l'industria musicale

Contesto e motivazione del progetto

Trasformazione del Mercato

L'industria musicale è in profonda trasformazione grazie all'evoluzione tecnologica e all'adozione dell'IA.

Le piattaforme

Piattaforme come Spotify, Apple music e altre hanno convertito il mercato in un ecosistema relazionale complesso guidato da algoritmi di raccomandazione.

Automazione e Metodologia

Tecnologia e automazione possono comparire anche nei testi: l'analisi prova a verificare se emergano come dimensione semantica riconoscibile.

Idea centrale: non usare Network Science e Text Mining separatamente, ma collegarne i risultati.

Tre domande di ricerca

La struttura del progetto segue direttamente questi tre quesiti

RQ1

STRUTTURA RELAZIONALE

Come collaborazioni e co-occorrenze nei crediti definiscono gerarchie e posizionamento degli artisti?

RQ2

TEMATICHE LATENTI

Quali temi emergono dai testi e quanto tecnologia/digitale/automazione costituiscono una dimensione riconoscibile?

RQ3

INTERSEZIONE

La posizione dell'artista nella rete è associata alla tendenza a esplorare contenuti relativamente più tecnologici?

Dataset utilizzati

Due fonti complementari: struttura musicale e contenuto testuale

SPOTIFY TRACKS

- Metadati dei brani e artisti accreditati.
- Popularity del brano.
- Audio features utilizzate nell'analisi statistica.
- Base per la costruzione della rete di co-occorrenza.

> 100k brani raw

89.738 dopo la pulizia

GENIUS SONG LYRICS

- Corpus di testi molto più grande di Spotify.
- Lettura selettiva per evitare di processare inutilmente tutto il dataset.
- Fonte del contenuto linguistico per tokenizzazione e LDA(LATent Dirichlet Allocation).
- Analisi finale limitata ai testi classificati come inglesi.

Obiettivo del join

collegare ogni testo a metadati e artisti Spotify

Matching Spotify ↔ Genius

Il problema principale: nessun identificatore univoco condiviso

89.738

Spotify puliti

80.126

chiavi titolo-artista

18.411

match finali

22,98%

matching rate

1 Normalizzazione
titolo

2 Artista principale

3 Chiave titolo +
artista

4 Join esatto

Controllo manuale

30 corrispondenze controllate qualitativamente: utile come sanity check, ma non come stima formale dell'accuratezza.

Conseguenza

Le conclusioni testuali valgono per il sottoinsieme effettivamente allineato, non per l'intero dataset Spotify.

Pipeline completa

Dai dati grezzi all'integrazione tra rete, testi e popolarità

1

Pulizia
Spotify

2

Matching
Genius

3

Network
artists

4

Lyrics
preprocess
ing

5

LDA +
proxy tech

6

Join per
artista/bran
o

7

Correlazio
ni
+
regression
e

Network Science

descrive la posizione strutturale degli artisti

Text Mining

descrive la composizione tematica dei testi

Integrazione

verifica se struttura, temi e popolarità sono associati

Costruzione della rete

Grafo non orientato e pesato basato sui crediti condivisi

Definizione

- Nodo = artista accreditato.
- Arco = due artisti compaiono nello stesso brano.
- Peso = numero di brani in cui la coppia compare insieme.
- Artisti presenti soltanto in brani solisti non entrano nella rete.

Interpretazione del peso

w_{ij} = numero di co-occorrenze

Più alto è il peso, più frequentemente i due soggetti sono accreditati insieme.

Attenzione

Il grafo rappresenta crediti condivisi: può includere featuring, compositori, interpreti e orchestre.

Metriche di centralità

Tre prospettive diverse sulla posizione di un artista

STRENGTH

Somma dei pesi degli archi.
Misura il volume complessivo delle co-occorrenze.

PAGERANK

Premia nodi collegati ad altri nodi rilevanti.
Considera anche la qualità strutturale dei vicini.

CORE BETW.

Misura quanto un nodo funge da ponte tra percorsi.
Calcolata sul nucleo dei 2.500 artisti più forti.

Per la betweenness i pesi sono trasformati in distanza come $1 / \text{weight}$.

Motivo: in igrph un peso maggiore viene interpretato come distanza maggiore, mentre qui una collaborazione più frequente deve rappresentare maggiore vicinanza.

Risultati della rete

Una struttura ampia, eterogenea e non limitata ai featuring

19.655

artisti con co-occorrenze

38.670

relazioni

627

Pritam · Strength

557 / 441

Mozart / Arijit Singh

Grafico Ponderato delle Collaborazioni Musicali

Dimensione nodo = Weighted Degree | Colore = Comunità Louvain




Cosa mostra il ranking?

- La rete non coincide con il solo mercato pop contemporaneo.
- La presenza di Mozart segnala l'effetto dei crediti di compositori/interpreti/orchestre.
- Strength elevata = molte co-occorrenze pesate, non necessariamente maggiore popolarità.

Le centralità misurano la stessa cosa?

Confronto delle metriche per verificare ridondanza e complementarità




Lettura

- Correlazioni alte → metriche ordinano gli artisti in modo simile.
- Correlazioni più basse → ruoli strutturali differenti.
- Strength = volume.
- PageRank = autorevolezza dei vicini.
- Betweenness = intermediazione nel core.

Community detection con Louvain

Ricerca di gruppi con alta densità interna di connessioni



COMMUNITY 15

J Balvin · Bad Bunny
Daddy Yankee

COMMUNITY 28

David Guetta · Tiësto
Martin Garrix

COMMUNITY 126

Compositori, interpreti
e orchestre classiche

Sono community strutturali, non
etichette di genere validate.

Preparazione dei testi

Dal testo Genius alla Document-Term Matrix

1 Rimozione
elementi
specifici
Genius

2 Normalizzazio
ne
e
tokenizzazione

3 Stopword
removal

4 Filtro per
frequenza
documentale

5 Costruzione
DTM

18.195

documenti originali

18.181

documenti nella DTM

12.806

termini

714.012

celle non nulle

Frequenza documentale minima = 5

Solo 14 documenti vengono esclusi nel passaggio alla DTM.

Topic Modeling: come viene scelto LDA

Valutazione out-of-sample tramite training/test

80% TRAIN

Addestramento di un modello LDA per ogni valore candidato di k.

20% TEST

Valutazione su documenti non usati durante l'addestramento.

PERPLEXITY


Più bassa = migliore capacità di rappresentare il test set.

N.B Seed = 1234

per rendere riproducibili split e addestramento, compatibilmente con le versioni dei pacchetti.

Scelta del numero di topic

k = 10 è il migliore tra i candidati testati



10

topic selezionati

1659,56


perplexity

Interpretazione corretta

- La perplexity diminuisce per tutti i candidati.
- Il minimo è al limite superiore del confronto.
- Quindi 10 è supportato per questa analisi, ma non è dimostrato come numero ottimale assoluto.

Che cosa rappresentano i 10 topic?

Le parole più probabili consentono una lettura semantica indicativa



Esempi interpretativi

- Topic 1 → spiritualità, conflitto, morte.
- Topic 3 → perdita e dolore.
- Topic 8 → relazioni sentimentali.
- Topic 9 → lessico rap esplicito.
- Topic 10 → dancehall / reggae.

Dominant topic = topic con γ massimo per il brano.

γ resta una distribuzione: un testo può mescolare più temi.

Come viene definito il proxy tecnologico

Il dizionario non addestra LDA: viene applicato dopo il topic modeling

β probabilità delle parole all'interno di ogni topic

γ probabilità dei topic all'interno di ogni documento

Dizionario tecnologico post hoc

Per ogni topic si somma la massa β assegnata ai termini del lessico digitale/tecnologico. Il topic con massa maggiore diventa il riferimento relativo per il proxy.

Perché è importante?

- LDA resta non supervisionato.
- Il dizionario serve solo per interpretare i topic dopo l'addestramento.
- Il proxy non è una classe certa «tecnologico / non tecnologico».
- Non è un detector di testi generati da IA.

Risultato sul tema tecnologia

Il Topic 2 è il più vicino al dizionario, ma non è un vero «topic tecnologico»

0,006548

massa β digitale · Topic 2


0,005213

secondo topic

1,26×

rapporto

**head · stop
break · hands**



Conclusione

Non emerge una categoria latente chiaramente dedicata a tecnologia, digitale o automazione.

Il Topic 2 è soltanto relativamente più vicino al dizionario rispetto agli altri topic.

Integrazione: rete × testi

Le variabili testuali vengono aggregate per artista prima delle correlazioni

Aggregazione

- Ogni brano contribuisce al profilo degli artisti accreditati.
- Per le correlazioni si considerano artisti associati ad almeno 2 brani.
- Obiettivo: evitare che un singolo testo rappresenti l'intera produzione osservata di un artista.
- Spearman è scelto perché le centralità sono asimmetriche.


Correlazioni con il proxy tecnologico

Strength	-0,0343
Core betweenness	-0,0896
PageRank	+0,0267
Popolarità media	+0,0567

Tutti i valori sono molto vicini a zero → nessuna relazione monotona sostanziale.

Modello statistico esplorativo

Popolarità ~ proxy testuale + centralità + caratteristiche acustiche



3.919

osservazioni complete

0,06237

R^2

0,06045

R^2 corretto

≈ 6,24%

varianza spiegata

Le centralità sono trasformate con $\log_{10}()$ per ridurre l'asimmetria.

Il test complessivo può essere significativo, ma la capacità esplicativa è debole e non autorizza interpretazioni causali.

Conclusioni, limiti e sviluppi

Che cosa possiamo realmente affermare dopo l'analisi?

RISULTATI

- Rete eterogenea di 19.655 artisti e 38.670 relazioni.
- 10 topic LDA interpretabili.
- Nessun topic autonomo chiaramente tecnologico.
- Correlazioni rete-proxy quasi nulle.
- Regressione con $R^2 \approx 6,24\%$.

LIMITI

- Matching 22,98% senza ID univoco.
- Crediti $\neq$ solo featuring.
- Solo lyrics inglesi disponibili su Genius.
- $k=10$ non è optimum assoluto dimostrato.
- Proxy post hoc relativo.
- Betweenness su 2.500 artisti; regressione su 3.919 casi.
- Associazioni $\neq$ causalità.

SVILUPPI

- Usare ISRC o identificatori condivisi.
- Validare un dizionario tecnologico più specifico.
- Modello supervisionato per distinguere veri riferimenti tecnologici da semplici occorrenze lessicali.
- Ampliare la ricerca di k e usare metriche di coerenza.
- Separare featuring, compositori, interpreti e orchestre.

Messaggio finale: con questi dati e questo metodo non c'è evidenza sufficiente per sostenere che il settore musicale sia già organizzato attorno alla tecnologia.